# 온톨로지 정형화 (PDF → JSON) 작업 기록

DLR 온톨로지 사양 v3.00 + FAA JO 7110.65BB → `configs/ontology.json`

Team 6 (XAI616 Knowledge-Based Systems)

2026-10-15 생성 코드: `src/kb/build_ontology.py` 출력: `configs/ontology.json` (v1.0)

**요약**

- 문서 (PDF) 3 개를 근거로, 파이프라인이 읽는 온톨로지 파일 `configs/ontology.json` 을 **코드로 생성**했다.
- 원칙: **우리가 정한 것 (설계)** 과 **문서가 말하는 것 (근거)** 을 분리하고, 근거로 적은 내용은 **빌드할 때 PDF 원문과 자동 대조**한다. 하나라도 원문에 없으면 빌드가 실패한다.
- 결과: 명령 종류 20 개 모두 검증 통과. 18 개는 DLR 공식 명령에 대응되고, 2 개 (MONITOR, REQUEST) 는 미국 확장이다.
- 파이프라인이 실제로 쓰는 값 (복창 필수 목록, 대체 규칙 등) 은 이전 v0.1 과 동일하다. 근거 정보만 추가됐다.

## Contents

**1 입력 자료** **2**

**2 전체 흐름** **2**

**3 단계별 방법** **2**

3.1 설계값 정의 (사람이 정함) . . . 2
3.2 DLR 명령 표 파싱 (Table 1 쪽) . . . 2
3.3 DLR 매개변수 표 파싱 (Table 2 쪽) . . . 3
3.4 FAA 조항 분할과 표준 문구 탐색 . . . 3
3.5 검증 규칙 (하나라도 실패하면 생성 중단) . . . 3
3.6 출력 조립 . . . 3

**4 FAA 복창 등급** **3**

**5 매핑 결과 (20 개 종류)** **4**

**6 출력 JSON 구조** **5**

**7 호환성 확인** **5**

**8 재현 방법** **5**

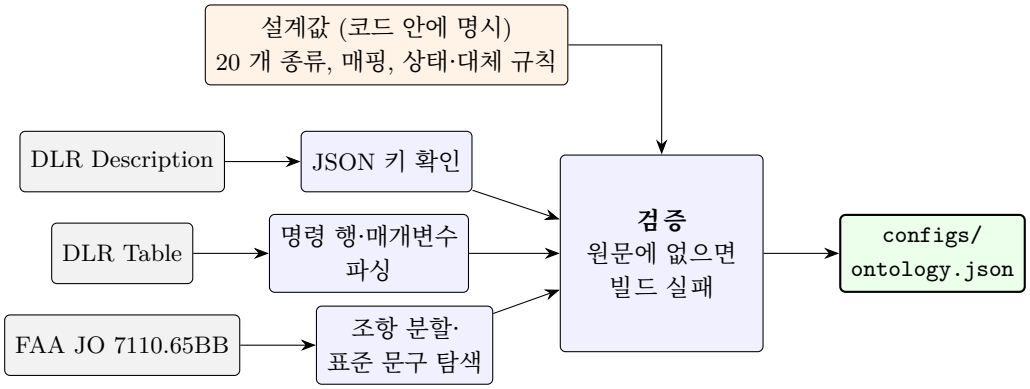
**9 한계** **6**

# 1 입력 자료

세 파일은 `data/ontology/`에 둔다. 저장소에는 올리지 않는다 (`.gitignore`). DLR 문서에는 재배포 제한 문구가 있고, FAA 파일은 9 MB 이기 때문이다. 대신 출력 JSON 의 `generated.inputs` 에 각 파일의 MD5 를 기록해 어떤 판으로 만들었는지 남긴다.

| 파일 | 가져오는 내용 | 출처 |
|---|---|---|
| `OntologyATCCommands Description_v20250704.pdf` (52 쪽) | 지시 (Instruction) 의 구성 요소 (2 장), JSON 교환 키 정의 (5.1 장) | DLR-IB-FL-BS-2025-107 v3.00, https://elib.dlr.de/214852 |
| `OntologyATCCommands Table_v20250704.pdf` (2 쪽) | 1 쪽: 명령 약 90 종의 Type (Main/Sub), 값, 단위, 한정어, 조건. 2 쪽: 값 형식 (매개변수) | 위와 같은 elib 기록의 첨부 |
| `FAA 규정.pdf` (732 쪽) | 명령별 표준 문구 (phraseology) 와 조항, 복창 규정 (§2-4-3) | FAA Order JO 7110.65BB (2025-02-20 시행) |

# 2 전체 흐름




모든 PDF 는 `pdftotext -layout`(poppler) 으로 텍스트로 바꾼다. `-layout` 은 표의 열 위치를 공백으로 보존하므로, 글자의 **가로 위치**로 어느 칸인지 판단할 수 있다.

# 3 단계별 방법

## 3.1 설계값 정의 (사람이 정함)

코드 맨 위 `COMMAND_TYPES` 에 20 개 종류를 적는다. 종류마다 적는 항목은 다음과 같다.

- `dlr`: 대응하는 DLR 표의 (Type Main, Type Sub). 예: `CLEARED_FOR_TAKEOFF` → (`CLEARED`, `TAKEOFF`). Sub 칸이 비어 있으면 `None`, 아무 Sub 나 허용하면 `*`.
- `faa`: (조항 번호, 그 조항에 있어야 할 표준 문구의 정규식). 예: `HOLD_SHORT` → (3-7-2, `READ BACK HOLD INSTRUCTIONS`).
- `faa_readback`: FAA 복창 등급 (§4). `icao_readback`: ICAO 기준 복창 여부.
- KG 용 설계값: `state`(유효 구간을 가지는지), `targets`, 대체 규칙, 최대 유효시간, 오탐 방지 키워드 (`lexical_cues`). 이 값들은 규정이 아니라 설계값이라고 JSON 의 `scope_notes` 에 밝힌다.

## 3.2 DLR 명령 표 파싱 (Table 1 쪽)

1. 머리글 줄에서 각 열 제목 (`Type (Main)`, `Type (Sub)`, `Value(s)`, `Unit`, `Qualifier(s)`, `Condition(s)`) 의 시작 위치를 잰다.

2. 각 줄을 “공백 2 칸 이상” 으로 나눈 조각으로 자르고, 조각의 시작 위치로 열을 정한다. 줄마다 1–2 글자씩 밀리는 경우가 있어 3 글자 여유를 둔다.
3. `Taxi types` 처럼 “types” 로 끝나는 한 조각 줄은 **분류 (category)** 로 기록한다.
4. Main 칸이 빈 줄은 칸 안에서 **줄바꿈된 글자**다. 표가 여러 줄 칸을 세로 가운데 정렬하므로 다음 행에 합친다. 예: `4-digit-squawk-value,` 줄이 아래의 `SQUAWK` 행 값으로 합쳐진다.
5. 결과: 명령 행 126 개.

### 3.3 DLR 매개변수 표 파싱 (Table 2 쪽)

표의 값 칸에는 `runway`, `TX-Point`, `Dir-Qualifier` 처럼 **매개변수 이름**이 들어 있고, 실제 형식은 2 쪽에 있다. 2 쪽을 같은 방식으로 파싱해 매개변수 60 개를 얻는다. 명령 행에서 쓰인 이름만 찾아 붙인다.

- 대문자 단어 (`LEFT`, `EXPEDITE`) 는 직접 값이므로 찾지 않는다.
- 표 자체의 오타 (`Alt-Qualfier`) 는 유사도 0.85 이상이면 같은 이름으로 본다.

### 3.4 FAA 조항 분할과 표준 문구 탐색

1. `3-7-2. TAXI AND GROUND MOVEMENT OPERATIONS` 처럼 “번호. 제목” 형태의 줄을 조항 시작으로 본다. 원문은 하이픈 대신 -(U+2212) 를 쓴다.
2. 목차 줄 (점선 . . .) 과 색인에 반복되는 제목은 버리고, **본문의 첫 등장**만 쓴다. 결과는 675 개 조항이다.
3. 각 종류의 (조항, 문구) 에 대해, **그 조항 본문 안에** 문구가 있는지 찾는다. 있으면 앞뒤 60 자를 인용 (`quote`) 으로 저장한다. 다른 조항에만 있으면 그 조항 번호를 오류 메시지로 알려 준다.

### 3.5 검증 규칙 (하나라도 실패하면 생성 중단)

| 검증 | 내용 |
|---|---|
| DLR JSON 키 | `csgn`, `type`, `sndT`, `valu`, `vare`, `qual`, `unit`, `speaker`, `reas`, `cond` 가 Description 원문에 정의되어 있는가 |
| DLR 명령 | 매핑한 (Main, Sub) 행이 표에 실제로 있는가 |
| FAA 조항 | 조항 번호가 실제 본문 제목으로 있는가, 그 본문에 표준 문구가 있는가 |
| FAA 복창 등급 | 각 등급의 근거 문장이 §2-4-3 본문에 있는가 |

### 3.6 출력 조립

검증을 통과한 정보와 설계값을 합쳐 JSON 으로 저장한다. 파이프라인 코드 (M4, M6, M7, E3) 가 읽는 키는 이름과 의미를 그대로 유지한다.

## 4 FAA 복창 등급

FAA §2-4-3(PILOT ACKNOWLEDGMENT/READ BACK) 을 읽어 보면, 복창 요구의 강도가 지시마다 다르다. 그래서 “복창 필수 여부” 를 한 비트가 아니라 **등급**으로 기록했다.

| 등급 | 원문 근거 (§2-4-3) | 해당 종류 |
|---|---|---|
| `acknowledge` | “Ensure pilots acknowledge all Air Traffic Clearances and ATC Instructions” (모든 지시는 응답 필요) | 전체 |
| `mandatory` | “Ensure the read back of hold short instructions” | HOLD_SHORT |
| `runway_assignment` | “Initial read back of a taxi, departure or landing clearance should include the runway assignment” | TAXI_VIA, CLEARED_FOR_TAKEOFF, CLEARED_TO_LAND |
| `numbers` | “pilots should read back the ‘numbers’ ” | CONTACT, MONITOR, CLIMB, DESCEND, HEADING, SQUAWK |
| `design` | 규정에 명시 없음. 활주로 진입이나 이동 정지를 허가하는 지시라서 우리가 필수로 정함 | CROSS_RUNWAY, LINE_UP_AND_WAIT, HOLD_POSITION |

`readback_required.FAA` 는 등급이 있는 13 개 종류이고, v0.1 과 같은 목록이다. ICAO 목록은 입력 파일에 ICAO 문서가 없어서 **검증하지 못했다**고 `readback_basis.ICAO` 에 명시했다.

# 5 매핑 결과 (20 개 종류)

| 우리 종류 | DLR (Main Sub) | FAA 조항 (검증된 표준 문구) | FAA 복창 등급 |
|---|---|---|---|
| TAXI_VIA | TAXI Preposition (VIA/TO) | 3-7-2 “taxi clearance/route must include the specific route” | runway_assignment |
| HOLD_SHORT | HOLD_SHORT | 3-7-2 “READ BACK HOLD INSTRUCTIONS”, 2-4-3 | mandatory |
| CROSS_RUNWAY | CROSS | 3-7-2 “CROSS (runway)” | design |
| HOLD_POSITION | HOLD_POSITION | 3-7-2 “HOLD POSITION” | design |
| GIVE_WAY | GIVE_WAY | 없음 (표준 문구 없음, 신호등 설명에만 등장) | – |
| FOLLOW | FOLLOW | 3-7-2 “FOLLOW (traffic)” | – |
| CONTACT | CONTACT, CONTACT_FREQUENCY | 2-1-17 “CONTACT (facility name …)” | numbers |
| MONITOR | 없음 *(미국 확장)* | 2-1-17 예문 “Monitor Tower”, “Monitor Ground” | numbers |
| LINE_UP_AND_WAIT | LINEUP | 3-9-4 “LINE UP AND WAIT” | design |
| CLEARED_FOR_TAKEOFF | CLEARED TAKEOFF | 3-9-10 “CLEARED FOR TAKEOFF” | runway_assignment |
| CLEARED_TO_LAND | CLEARED LANDING | 3-10-5 “CLEARED TO LAND” | runway_assignment |
| TURN | TURN | 3-10-9 “TURN LEFT/RIGHT (taxiway/runway)” | – |
| CLIMB | CLIMB | 4-3-2 “CLIMB AND MAINTAIN” | numbers |
| DESCEND | DESCEND | 4-5-7 “CLIMB/DESCEND AND MAINTAIN” | numbers |
| HEADING | HEADING (2 개 행) | 5-6-2 “TURN LEFT/RIGHT HEADING” | numbers |
| SQUAWK | SQUAWK | 5-2-1 “SQUAWK (code)” | numbers |
| TRAFFIC_INFO | INFORMATION TRAFFIC | 2-1-21 “TRAFFIC, (number) O’CLOCK” | – |
| WAKE_ADVISORY | CAUTION WAKE_TURBULENCE | 2-1-20 “CAUTION WAKE TURBULENCE” | – |
| ACK | AFFIRM (일부만 대응) | 2-4-3 “Wilco,” “Roger,” | – |
| REQUEST | 명령 아님: Speaker=PILOT, Reason=REQUEST | – | – |

# 6 출력 JSON 구조

| 키 | 내용 | 비고 |
|---|---|---|
| `generated` | 생성 코드, 날짜, 입력 파일 MD5 | 신규 |
| `sources`, `scope_notes` | 출처 문장, 범위와 설계값 표시 | 갱신 |
| `dlr_instruction_schema` | DLR 요소 → JSON 키 → 우리 M4 필드 대응 | 신규 |
| `command_types.*.dlr` | DLR 표 행 (분류, 값, 한정어, 조건) 과 매개변수 형식 | 신규 |
| `command_types.*.faa` | 조항 번호, 제목, 원문 인용 | 신규 |
| `command_types.*.readback` | {FAA: 등급, ICAO: 참/거짓} | 신규 |
| `readback_basis` | FAA 등급별 근거 인용, ICAO 미검증 표시 | 신규 |
| `state`, `targets`, `description` | KG 상태 의미 | 동일 |
| `readback_required`, `region_rules` | 복창 판정에 쓰는 목록 | 동일 |
| `supersedes`, `max_validity_sec`, `runway_state_types` | 시간 의미론 설계값 | 동일 |
| `lexical_cues` | LLM 추출 오탐 방지 키워드 | 동일 |

예시 (HOLD_SHORT, 일부 생략):

```
"HOLD_SHORT": {
  "state": true, "targets": ["Runway", "Taxiway"],
  "dlr": [{"category": "Ground hold types", "main": "HOLD_SHORT",
           "value": "runway/TX-Point/Alphabet-Letter",
           "parameters": {"runway": "runway_without_none + \"none\"",
                          "TX-Point": "Name of defined Taxi-Point ... such as A (alfa), B1, HP_05R"}}],
  "faa": [{"section": "3-7-2", "title": "TAXI AND GROUND MOVEMENT OPERATIONS",
           "quote": "... PHRASEOLOGY- READ BACK HOLD INSTRUCTIONS ..."},
          {"section": "2-4-3", "title": "PILOT ACKNOWLEDGMENT/READ BACK",
           "quote": "... b. Ensure the read back of hold short instructions ..."}],
  "readback": {"FAA": "mandatory", "ICAO": true}
}
```

# 7 호환성 확인

생성 결과를 v0.1 과 비교했다. `readback_required`, `region_rules`, `supersedes`, `max_validity_sec`, `runway_state_types`, `lexical_cues`, `advisory_types`, `non_instruction_types`, `entity_types`, `relation_types` 와 20 개 종류의 `state·targets·description` 이 **모두 동일**하다. 따라서 기존 KG 결과 (`results/katl_all`) 는 다시 만들 필요가 없다.

# 8 재현 방법

```
# data/ontology/ 에 PDF 3개를 둔 뒤
python src/kb/build_ontology.py                  # configs/ontology.json 생성
python src/kb/build_ontology.py --out /tmp/o.json   # 다른 경로로 시험 생성
```

매핑을 바꾸려면 코드의 `COMMAND_TYPES` 만 고치고 다시 실행한다. 원문에 없는 근거를 적으면 어떤 항목이 왜 실패했는지 출력하고 멈춘다.

# 9 한계

**한계와 주의**

- **매개변수 표 줄바꿈:** DLR 표 2 쪽에서 여러 줄로 나뉜 칸 일부가 잘려 들어온다 (예: `altitude` 는 "or none" 만, `4-digit-squawk-value` 는 빈 값). 1 쪽 명령 행은 정확하다.
- **조건·단위 미추출:** DLR 의 Condition(UNTIL/WHEN/IF/AFTER) 과 Unit 은 표에서 옮겨 적기만 했고, M4 추출에서는 아직 쓰지 않는다.
- **ICAO 미검증:** ICAO 복창 목록은 Doc 4444 를 입력으로 넣지 않아 자동 검증 대상이 아니다.
- **매핑은 사람이 정함:** 우리 종류와 DLR 행의 대응 (예: TAXI_VIA → TAXI VIA/TO) 은 사람이 판단했다. 코드는 그 행이 존재하는지만 확인한다.
- **문구 위치 검증:** FAA 표준 문구가 해당 조항에 "있다" 는 것만 확인한다. 그 조항이 그 지시의 유일한 근거라는 뜻은 아니다.