U.S. ATC Radio Communications as an Event-Centric Temporal Knowledge Graph

복창 검증과 상황 인식을 위한 미국 관제 교신 KG 구축 — 발표 정리본

Team 6 (XAI-616 Knowledge-Based Systems)

2026-10-14 (v2: 구현·실측 결과 반영)

이 문서의 구조

Team 2 발표 (*Semiconductor Supply Chain Mapping in EDC Style*) 의 흐름을 그대로 따랐다: **문제정의** → **목표·접근** → **데이터·추출** → **온톨로지** → **정규화** → **융합** → **품질 입증** → **활용** → **결론**. 각 절의 첫 상자가 슬라이드 한 장의 요점이고, 본문은 발표자 노트·질의응답 근거다. 조사 과정에서 논리가 비어 있던 곳은 노란 상자 로 표시해 채웠다. 상세 수식 명세는 별도 문서 *system_module.pdf* 를 참조한다.

§	Team 2 슬라이드	Team 6 대응
1	Motivation & Problem	복창 루프의 안전 중요성, 기존 연구의 공백, RQ1–RQ4
2	Goals & Approach	사건 중심 Temporal KG, 목표 사건 예시, 파이프라인
3	Extraction: SEC / Wikipedia	데이터 소스 개요 (HF LiveATC KATL), STT 추출 과정, 추출 예시
4	Ontology Definition	고정 스키마, 개체·관계 유형표 (정의역 → 치역), 인스턴스 예시
5	Canonicalization: Company & Offering	콜사인 해소, 값·고유명사 정규화, 정적 KB 연결
6	Canonicalization: Fusion	지시–복창 교차 확인 (두 화자 = 두 출처), 유효 구간, 신뢰도 등급
7	Evaluation: Recall / Precision	질적 평가 (역량 질문) + 근거 대비 정밀도 감사 + 주입 오류 탐지 + RQ4 진단
8	KG Exploration	지상 관제 상황 질의·사후 안전 분석 QA 데모
9	Conclusions	기여, 한계, 시사점, 다음 단계

1 Motivation & Problem

슬라이드 요점

- **관제 교신이란?** 관제사가 지시하고, 조종사가 복창 *(readback)* 하고, 관제사가 청취 확인 *(hearback)* 하는 루프. 이 루프가 오해를 막는 1 차 방어선이다 [1].
- **왜 중요한가?** 미국 FY2023 활주로 침범 **1,756 건** (그중 심각 A/B 급 **23 건**), 약 60% 가 조종사 이탈 [3]. 유럽 통신 사고 535 건에서 복창/청취 오류가 가장 흔하고, **유사 콜사인이 33%** 에 기여 [4].
- **기존 노력의 한계:** 자동 복창 오류 탐지는 발화 단위 개념 비교에서 멈춤 [12]. 항공 KG 는 정형 데이터로만 구축 [16, 17]. 교신은 음성으로만 존재해서 질의·검증이 불가능하다.

근거 수치.

- **활주로 침범**: FAA FY2023, 이착륙 약 5,440 만 회 중 활주로 침범 1,756 건 (100 만 회당 32 건). 심각 A/B 급 23 건. 원인은 조종사 이탈 약 60%, 관제사 약 20%, 차량·보행자 약 20% [3]. 지상 이동 중의 지시 오해는 활주로 침범으로 직결될 수 있다.

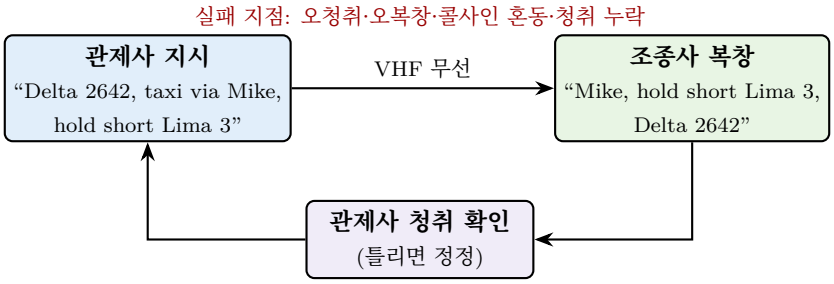


Figure 1: 지시–복창–청취 확인 루프. 우리 KG 는 이 루프의 각 단계를 사건으로 기록하고 일치 여부를 질의 가능하게 만든다. 예시 문구는 실제 KATL 전사 (§3) 에서 가져왔다.

- **복창 오류의 양상**: 미국 관제탑 교신 49 시간을 분석한 결과, 복창 오류율은 1% 미만이었다. 그러나 **같은 번호의 좌/우 활주로 혼동**이 가장 흔했고, **조종사가 다른 콜사인으로 응답**한 경우가 0.9% 였다 [6]. 메시지가 복잡할수록 오류가 늘었다 [5, 7].
- **공항 규모**: KATL 은 2024 년 여객 약 1 억 800 만 명으로 세계 1 위이고, 운항 횟수도 1 위다 [8]. 교통량이 많을수록 관제사의 청취 확인 부담이 커진다.

기존 노력과 공백.

흐름	대표 연구	한계 (우리가 메우는 부분)
음성 기반 복창 오류 탐지	DLR/Idiap, 단어 비교 실패 → 온톨로지 개념 비교, Isavia 실데이터에서 81% 탐지 [12, 13]	발화 단위 비교. 항공편 이력·시간·정적 지식이 누적되는 구조가 없음
ATM 지식 그래프	NASA ATMGRAPH [16], JKU 인공 상황 인식용 ATC KG [17]	비행계획·항공정보 같은 정형 데이터로 구축. 음성 교신을 입력으로 쓰지 않음
LLM 기반 추출·복창 감시	명령 구조화 추출 [18], SCOPE [19]	추출·분류에서 끝남. 지식이 축적·연결되지 않음

문제정의. 미국 관제 VHF 교신은 잡음 섞인 다화자 음성으로만 존재한다. 그래서 “어느 항공편이 무엇을 지시받았고 올바르게 복창했는가” 와 현재 지상 교통 상황을 **기계가 질의·검증할 수 없다**. STT 텍스트의 단어 비교는 콜사인 생략·바꿔 말하기·인식 오류 때문에 실패하고 [12], 발화 단위 개념 주석은 발화 간 관계·외부 맥락·시간축을 담지 못한다 [11].

- **RQ1 (표현)** 지시–복창–이관 관계와 그 유효 시간을 온톨로지 기반 사건 중심 Temporal KG 로 표현할 수 있는가?
- **RQ2 (교정·연결)** 정적 공항 지식과 발화 간 링크로 STT 오류 (콜사인, 유도로, 활주로) 를 탐지·교정할 수 있는가?
- **RQ3 (활용)** KG 위의 규칙·질의로 복창 오류와 지상 교통 상황을 인식할 수 있는가?
- **RQ4 (일반화)** 미국 기준으로 구축한 파이프라인을 한국·일본 교신에 추가 학습 없이 적용하면 어느 모듈에서 인식이 떨어지고, 지역 자원만 바꿔도 회복되는가?

2 Goals & Approach

슬라이드 요점

- 미국 관제 **음성**에서 지시·복창 **사건**을 추출해 **시간 정보를 가진 KG** 를 만들고, 그 위에서 복창 검증과 상황 질의를 시연한다.
- 접근은 EDC(Extract–Define–Canonicalize) [20] 를 따르되 세 가지를 바꿨다.
  - 스키마를 도메인 온톨로지로 사전 고정했다 [10, 21].
  - 트리플 대신 사건 *reification* 을 쓴다 [26].
  - 이중 시간 모델로 유효 구간을 관리한다 [25].
- **목표 사건 예시**:
  `[Instruction: HOLD_SHORT, target=Lima 3, flight=DAL2642, t=02:43:20Z] + [readback: MATCH] + [evidence: audio span, transcript]`

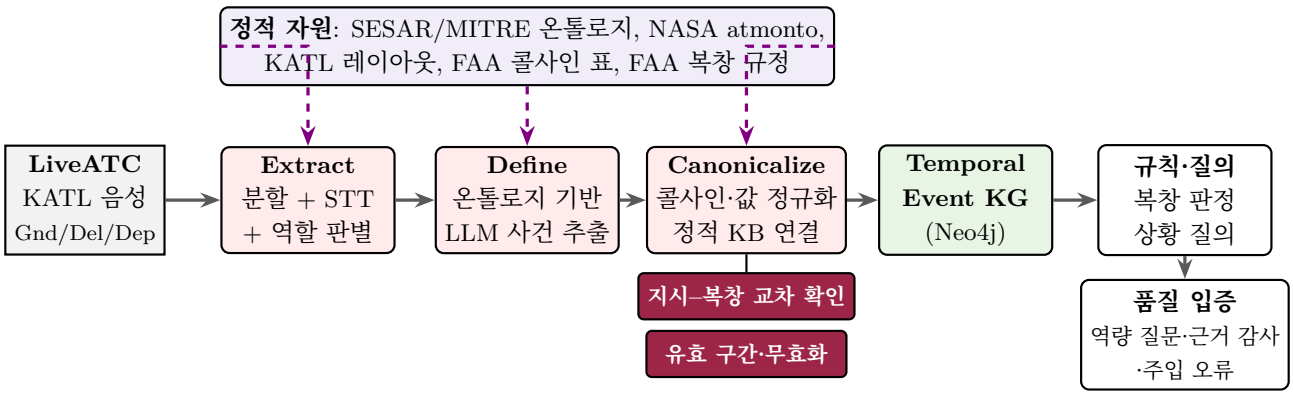


Figure 2: Team 6 파이프라인. 빨간 단계는 EDC 3 단계에 대응하고, 진한 빨간 상자는 우리 도메인에 맞춰 추가한 단계다. 9 개 모듈 단위의 형식 명세는 *system_module.pdf* 를 참조한다.

왜 EDC 를 그대로 쓰지 않는가.

- EDC 는 스키마가 없거나 큰 상황에서 개방형 추출 후 사후 정규화를 하는 방법이다 [20]. 우리 도메인에는 20 개 기관이 합의한 관제 명령 온톨로지가 이미 있고 [10, 11], 복창 비교에는 정규화된 개념이 필수다. 그래서 Define 단계를 앞당겨 스키마를 고정하는 온톨로지 기반 생성을 택했다 [21, 22]. Team 2 도 같은 이유 (“fusion and evaluation will be easier”) 로 스키마를 사전 고정했다.
- 관제 지시는 (항공편, 명령, 값, 단위, 대상) 으로 된 n-항 관계라 트리플 하나로 표현할 수 없다. 그래서 사건 노드로 reify 한다 [26, 27].
- 허가는 구간 동안만 유효하므로 사실별 유효 구간과 무효화가 필요하다 [25, 24].

3 Data & Extraction: HF LiveATC (KATL Ground)

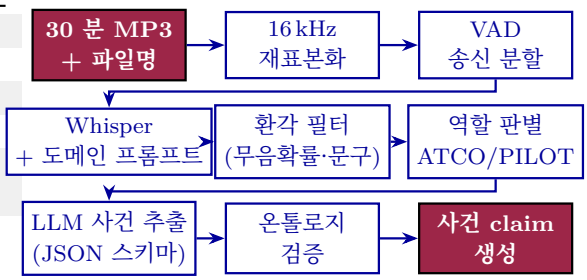
슬라이드 요점

- **HF LiveATC 를 선택한 이유:** 공개 ATC 음성 코퍼스 11 종 가운데 미국 실제 운영·양측 음성·연속 녹음·시각 메타데이터·즉시 확보를 모두 만족하는 것은 LiveATC 계열뿐이다.
- **전사가 없다는 점은 약점이 아니다:** 문제정의 (음성으로만 존재) 와 RQ2(STT 오류 교정) 를 그대로 재현하는 조건이다.
- **가장 많이 나오는 것:** 택시 경로, 대기 (hold short), 양보, Tower 이관 지시와 그 복창.

Source overview (실측)

Source	HF `nyuuzyou/liveatc` [32]
Feed	KATL Gnd-All (Atlanta Ground)
Source type	1 차 원천, 원본 VHF 음성 (MP3)
Files	11 개, 2024-08-26 00:00–05:30Z (5.84 h)
STT	Whisper large-v3 + 도메인 프롬프트, 30 분 파일당 약 41 s
Segments	1,860 (환각 의심 11 제외, 파일 겹침 제거 후 1,771)
Turns (M3)	1,775 (ATCO 1,027 / PILOT 745)
Extractor	Qwen3-4B-Instruct (로컬) + 규칙 문법, 약 17 분
Flights	513 (번호만 부른 콜사인 513 회 해소 시도)
ATCO instructions	1,088
Readback links	105 (MATCH 71 / PARTIAL 14 / MISMATCH 20)
Alerts	312

Extraction process



추출 예시 (KATL Gnd-All 02:30Z 파일, 전수 전사 결과 원문 그대로)

UTC	역할 (추정)	전사
02:43:04	PILOT	`Good evening, Delta 26-42, information, Papa, taxi at 4 south.`
02:43:20	ATCO	`Delta 26-42, on the ground, taxi via Mike, hold for the Lima-3.`
02:43:25	PILOT	`Mike, hold short, Lima-3, Delta 26-42.`
02:43:28	ATCO	`Delta 26-45, hold for the Lima-3.`

관제사 발화의 `on the ground` 는 *Atlanta Ground*, `hold for` 는 *hold short* 의 오인식으로 보인다 (같은 구간을 5 분만 잘라 전사했을 때는 `line of ground`, 2642 로 나왔다. 표기 변이 **C5**). 이어지는 복창의 `hold short` 와 유도로 이름 `Lima 3` 가 교차 확인 근거가 된다 (§6). 단어만 비교하면 불일치지만, 개념 단위로는 같은 지시다. 3 초 뒤의 `Delta 26-45` 는 다른 항공편인지, `26-42` 의 오인식인지 이 발화만으로는 판단할 수 없다. 이것이 유사 콜사인 문제이고, 그래프 문맥 (복창 유무, 이후 이력) 으로 판정해야 한다.

논리 보강 (이번 조사로 추가)

실측에서 나온 추가 근거.

- **콜사인의 88% 가 Delta** 다 (KATL 은 Delta 허브). 숫자만 다른 콜사인이 한 주파수에 몰리므로, 유사 콜사인이 통신 사고의 33% 에 기여한다는 결과 [4] 가 이 데이터에서 특히 중요하다. 콜사인 해소 (§5) 의 필요성을 데이터가 직접 보여준다.
- 콜사인이 문장 앞 (관제사형) 에 온 송신 512 개, 뒤 (조종사형) 에 온 송신 328 개. 콜사인 위치로 역할을 판별하는 단서가 실제로 작동할 만큼 패턴이 분명하다 [9].
- 활주로 `9 left` 가 `9 or left` 로, `Foxtrot` 이 `Fox Tractor` 로 전사되는 등 **정규화 대상이 반복적으로** 나온다. 콜사인이 `Alpha` 로 시작하는 오인식도 4 건 있었다.

데이터 선정 근거 (요약).

- ATCO2·UWB-ATCC 는 유럽 데이터이고 [33, 34], ATCOSIM 은 **관제사 음성만 있어서 복창이 없다** [35]. Airbus 는 비공개이고 [36], LDC ATC0 는 유료·1990 년대 데이터다 [37].
- 공개 수신 음성은 ATC 음성 연구의 표준 원천이다 [33, 31].
- 30 분 연속 녹음이라 지시 → 복창 → 이관이 끊기지 않고, 파일명에서 공항·시설·UTC 시각을 얻는다.
- **한계와 보완:** KATL 에는 Tower 피드가 없고, Gnd-All 은 48 개 파일 중 11 개만 음성이다. 착륙 허가 시나리오가 필요하면 TartanAviation KAGC(Tower + ADS-B) 를 보조로 쓴다 [38]. LiveATC 약관상 비상업 용도이고 재배포는 금지다 [32].

4 Ontology Definition

슬라이드 요점

- 스키마는 LLM 이 유도하지 않고 **사전 고정**한다. 기존 표준 온톨로지 (SESAR PJ.16-04 명령 체계 [10], MITRE–DLR 비교 [14], NASA atmonto [15]) 를 재사용한다.
- **8 개 개체 유형, 9 개 관계 유형, 18 개 명령 유형**. 명령 유형은 다시 복창 필수, 상태형 (유효 구간을 가짐), 정보형 (복창 대상 아님) 으로 나눈다.
- 추출기 출력은 JSON 스키마 제약 디코딩 [28] 과 SHACL 형태 제약 [29] 으로 검증하고, 위반은 격리한다.

관계 유형 (정의역 → 치역)

Relation	Subject → Object
SPOKEN_BY	Transmission → Role
ADDRESSES	Transmission → Flight
CONTAINS	Transmission → Instruction
TARGET	Instruction → Runway/Taxiway/Facility
READBACK_OF	Transmission(P) → Transmission(A)
NEXT	Instruction → Instruction (항공편별 순서)
OPERATED_BY	Flight → Airline
ALIAS	Flight → CallsignMention
PART_OF	Runway/Taxiway → Airport

명령 유형 분류

분류	예
복창 필수	HOLD_SHORT, CROSS_RUNWAY, 활주로 배정, CONTACT(주파수), 고도·기수 (FAA JO 7110.65 §2-4-3 [1])
상태형	CLEARED_TO_LAND/TAKEOFF, LINE_UP_AND_WAIT, HOLD_SHORT, CROSS_RUNWAY, CONTACT/MONITOR
정보형	TRAFFIC_INFO, WAKE_ADVISORY (복창 비교에서 제외)
기타	TAXI_VIA, GIVE_WAY, FOLLOW, TURN, SQUAWK, ACK

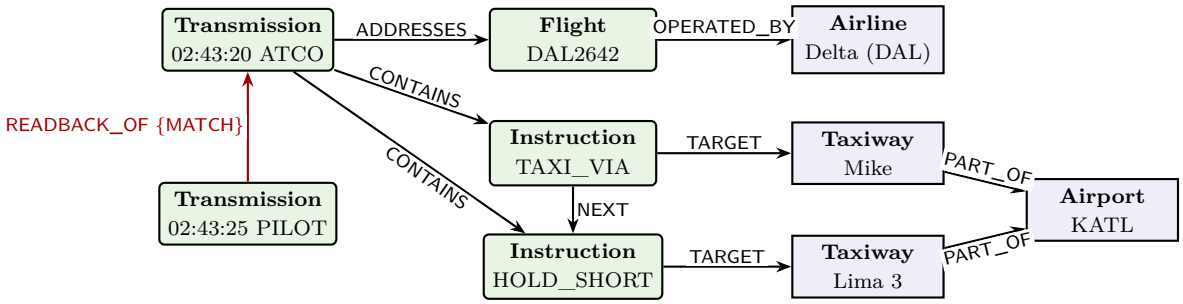
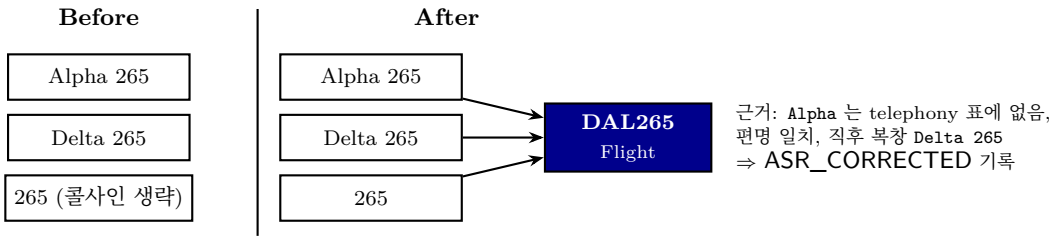


Figure 3: KG 인스턴스 예시 (§3의 실제 교환). 초록은 사건 계층으로 유효 구간·출처·신뢰도를 가지고, 보라는 정적 KB 계층이다.

5 Canonicalization: Callsigns & Values

슬라이드 요점

- **콜사인 해소:** `Alpha 265`, `Delta 265`, `265` 처럼 서로 다른 표면형을 하나의 `Flight` 노드로 합친다. 판단 근거는 FAA 콜사인 표 [2], 발음 유사도, 그래프 문맥 (직후 복창, 최근 활성 항공편) 이다 [30, 23].
- **값·고유명사 정규화:** 표기 변이와 오인식을 표준형으로 바꾼다. 예: `Fox, shot`→Foxtrot, `19-1`→119.1, `line of ground`→Atlanta Ground. 이어서 KATL 레이아웃의 실제 유도로·활주로 노드에 연결한다.
- 연결에 실패하면 버리지 않고 KB_VIOLATION 으로 남긴다. 오인식인지 맥락 오류인지 사후에 추적할 수 있다.



논리 보강 (이번 조사로 추가)

KG 가 STT 를 돕는 되먹임. 누적 그래프의 활성 콜사인과 유도로 이름을 다음 송신의 STT 프롬프트에 넣는다. 감시 데이터로 콜사인을 부스팅해 인식을 크게 개선한 선행연구 [30] 를, 라벨 없이 쓸 수 있는 형태로 근사한 것이다. 이 고리 때문에 RQ2("KG 로 STT 오류를 교정할 수 있는가") 가 단순 후처리가 아니라 구조적 장점이 된다.

6 Fusion: Cross-Speaker Corroboration & Temporal Validity

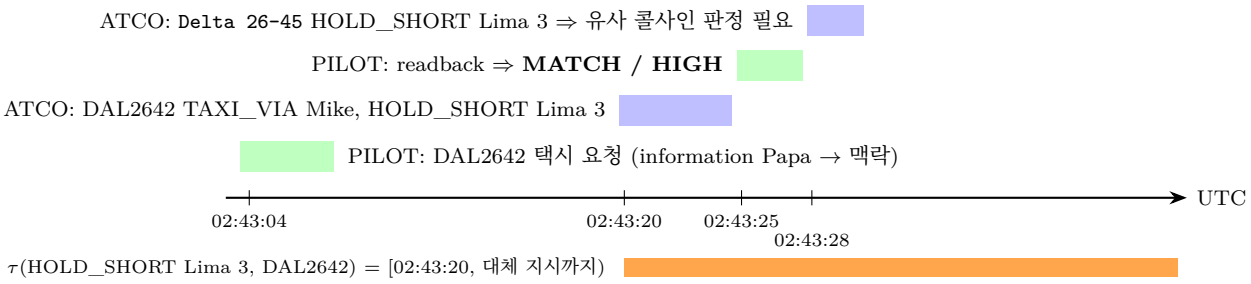
슬라이드 요점

- Team 2 는 두 출처 (SEC·Wikipedia) 에 같은 관계가 나오면 신뢰도를 올렸다 (두 출처 일치 시 정밀도 94%). 우리 도메인에서는 **관제사와 조종사가 독립된 두 출처**다. 지시와 복창의 개념이 일치하면 그 사실은 두 화자에게 교차 확인된 것이다.
- **신뢰도 등급**
  - **HIGH**: 지시–복창 개념 일치
  - **MEDIUM**: 한쪽 발화만 있음
  - **LOW**: STT 신뢰도가 낮거나, 교정 (ASR_CORRECTED) 이 개입됨
- **시간 융합**: 상태형 지시는 유효 구간을 가지고, 대체되는 지시가 오면 삭제하지 않고 무효화한다 [25]. 여러 주파수 (Del→Gnd→Dep) 의 송신을 UTC 로 병합해 같은 항공편의 이관 흐름을 잇는다.

논리 보강 (이번 조사로 추가)

왜 이 신뢰도 정의가 타당한가.

- 복창의 목적 자체가 "상대가 같은 내용을 이해했는지 독립적으로 확인" 하는 것이다 [1]. 그래서 일치는 사실의 정확성에 대한 증거가 된다.
- 반대로 불일치는 두 가지로 해석될 수 있다. (a) 실제 복창 오류, (b) 한쪽의 STT 오류. 두 경우를 섞지 않도록 불일치 경보에는 STT 신뢰도와 교정 이력을 함께 붙인다. 이것이 Team 2 의 "evidence traceability" 에 대응한다.
- 이 정의는 §7에서 등급별 정밀도로 검증한다. 가설은 "HIGH 의 근거 정밀도가 MEDIUM 보다 높다" 이다.



네 송신 모두 KATL Gnd-All 실제 전사다. 유효 구간의 종료 시점은 이후 대체 지시로 정해진다.

7 Quality Evaluation

슬라이드 요점

- 교수님 지침에 따라 KG 의 대규모 정량 평가는 하지 않는다. 대신 **질적 평가를 주로 하고, 근거가 명확한 소규모 정량 점검**으로 품질을 입증한다.
- **E1 역량 질문 (CQ)**: 온톨로지가 답해야 할 질문을 먼저 정하고, KG 가 답하는지 확인한다 (질적, [39]).
- **E2 근거 대비 정밀도 감사**: 관계 표본을 원음·전사와 대조한다 (Team 2 의 Precision 에 대응).
- **E3 주입 오류 탐지**: 복창 오류는 1% 미만으로 드물다. 그래서 정상 복창에 통제된 오류를 주입해 탐지율과 오경보율을 잰다 (Team 2 의 Recall 에 대응, [13]).
- **E4 RQ4 진단**: 한국·일본 교신에서 처음 실패한 모듈의 분포를 본다.

논리 보강 (이번 조사로 추가)

왜 평가를 보강했는가 (논리 공백 메우기).

1. "평가 생략 + 데모" 만으로는 데모 장면이 골라 뽑은 사례라는 반론을 막기 어렵다. Team 2 가 호평받은 지점도 문제정의를 입증하는 단계였다.
2. 우리 도메인에는 Team 2 의 ETO 같은 **외부 기준 데이터가 없다**. 그래서 재현율은 "KG 사실 재현율" 이 아니라 "이상 상황 탐지 재현율" 로 재정의한다.
3. 실제 복창 오류는 1% 미만이라 [6] 5.5 시간 데이터에 몇 건 없을 수 있다. 데모에서 오류 탐지를 보이려면 주입이 필요하다. 인공 복창 오류 표본은 DLR 연구에서도 관제사 실험에 쓰였다 [13].
4. 품질 차원은 Linked Data 품질 서베이의 정의를 따른다 [41].

E1. 역량 질문 기반 질적 평가

역량 질문은 "온톨로지가 답할 수 있어야 하는 질문" 으로 요구사항을 정의하고, 마지막에 이 질문들로 온톨로지를 검증하는 방법이다 [39, 40]. 판정 기준은 KG 에서 질의로 답이 나오는가 (통과/실패) 와 답에 근거 송신이 붙는가이다.

CQ	질문	관련 RQ	필요 구조
CQ1	DAL2642 가 받은 지시를 시간순으로 나열하면?	RQ1	NEXT, τ
CQ2	02:40–02:50Z 에 Lima 3 에서 대기 지시를 받은 항공편은?	RQ1, RQ3	TARGET, τ
CQ3	복창이 없거나 콜사인 없이 복창된 지시는?	RQ3	READBACK_OF
CQ4	복창과 지시의 유도로·활주로가 다른 경우는?	RQ3	개념 비교
CQ5	STT 교정이 개입된 콜사인과 그 근거 발화는?	RQ2	ALIAS, prov
CQ6	KATL 에 존재하지 않는 유도로가 언급된 송신은?	RQ2	정적 KB 연결
CQ7	Tower 로 이관된 뒤에도 Ground 지시를 받은 항공편은?	RQ3	MONITOR/CONTACT τ
CQ8	지금 (t) 활주로 8R 로 택시 중인 항공편은?	RQ3	스냅샷 $\mathcal{G}\|_t$

E2. 근거 대비 정밀도 감사

- **표본**: 관계 유형별 10 개씩, 약 60–80 개 (Team 2 의 수동 감사 79 개와 같은 규모).
- **판정**: 사람이 원음 구간과 전사를 듣고 "명시적으로 지지 / 부분 지지 / 지지 안 됨" 을 단다. 선택적으로 LLM 판정을 보조 의견으로 붙인다 (LLM-as-a-judge [42]).
- **보고**: 전체, 신뢰도 등급별 (HIGH/MEDIUM/LOW), 관계 유형별 정밀도. 표본이 작으므로 *Wilson 95%* 신뢰구간을 함께 보고한다 [43].
- **가설**: HIGH(교차 확인) > MEDIUM > LOW. 성립하면 §6의 신뢰도 정의가 검증된다.

E3. 주입 오류 탐지 (복창 이상 재현율)

정상 (MATCH) 쌍 N 개를 골라 복창 쪽 텍스트에 아래 변형 중 하나를 넣는다. 변형하지 않은 쌍은 오경보 측정용 대조군으로 남긴다.

유형	변형 예	근거	기대 판정
좌/우 혼동	`8 right→8 left`	가장 흔한 실제 오류 [6]	MISMATCH
유도로 치환	`Lima 3→Lima 4`	대상 오해	MISMATCH
콜사인 숫자 변경	`2642→2462`	유사 콜사인 [4]	MISMATCH 또는 미연결
필수 항목 누락	`hold short` 삭제	부분 복창	PARTIAL
콜사인 누락	끝의 콜사인 삭제	FAA §2-4-3 [1]	NO_CALLSIGN

보고 지표는 유형별 탐지율 (= 재현율) 과 대조군 오경보율이다. 텍스트 수준 주입은 STT 오류가 없는 상한을 재는 것이다. 그래서 같은 쌍의 원음 기반 결과 (오경보율) 와 나란히 보고한다.

E4. RQ4 진단 (한국·일본)

국가별 15–20 개 송신에 정답을 달고 콜사인 인식률, 명령 개념 F1, 처음 실패한 모듈 분포를 보고한다. 조건은 (a) 그대로 적용, (b) 지역 자원만 교체 두 가지다. 일본은 LiveATC, 한국은 VATSIM(모의 교신이라는 점을 명시) 또는 허가된 실제 녹취를 로컬에서만 처리한다.

평가 결과 (KATL Ground 5.84 h, 2026-10-14 실행)

평가	결과
E1 역량 질문	**8/8** 답변 가능·비어 있지 않음·원음까지 추적 가능. 예: CQ2 “8R 대기 지시를 받은 항공편” 12 건, CQ8 시점 스냅샷 84 건
E2 근거 정밀도	**잠정** 60.0% (95% CI 47.4–71.4, n=60), 판정은 추출과 다른 모델 (Qwen3.5-9B) 로 했다. 신뢰도별로 HIGH 80% (n=5) > MEDIUM 66.7% (n=24) > LOW 50% (n=8) 로 가설과 같은 방향이다. 관계별로는 TARGET 83%, ADDRESSES·VIA 67%, INSTRUCTION_TYPE 50%, READBACK_OF 33% 다. 확인해 보니 *LLM* 판정이 명백한 일치도 기각하는 경우가 있어 수치가 불안정하다. *60* 행 시트에 사람 라벨을 단 뒤 다시 보고한다.
E3 주입 오류	대조군 오경보 **0%** (n=71, CI 0–5.1). 탐지율: 콜사인 숫자 변경 **95.5%** (n=67), 콜사인 누락 **91.2%** (n=57), hold short 누락 100% (n=6), 유도로 치환 56.1% (n=66), 좌/우 활주로 25% (n=4). 규칙 추출기 기준선은 유도로 치환 90%, 콜사인 97.6%, 오경보 0% (n=41)
E4 RQ4	정답 템플릿 20 개 생성 (`data/gold/katl_gnd_gold_template.jsonl`). 일본·한국 데이터 확보 후 같은 절차로 실행

논리 보강 (이번 조사로 추가)

결과 해석.

- **콜사인 관련 이상은 잘 잡는다** (91–96%). 유사 콜사인이 사고 기여의 33% 라는 근거 [4] 와 연결되는 강점이다.
- **유도로 치환 탐지는 LLM(56%) 이 규칙 추출기 (90%) 보다 낮다.** LLM 이 복창에서 경로를 생략하면 비교 근거가 사라지기 때문이다. 결과적으로 정밀도와 탐지율 사이에 상충이 있고, 두 추출기를 함께 쓰는 하이브리드 설계의 근거가 된다.
- **좌/우 활주로 혼동**은 지상 복창에 활주로가 직접 언급되는 경우가 드물어 표본이 4 개뿐이다. Tower 데이터가 필요하다.
- **주의:** 실제 MISMATCH 경보 20 건 중 상당수는 추출 잡음으로 생긴 거짓 경보로 보인다 (예: 경로 일부만 복창한 경우). 데모에서는 경보를 검토 대상으로 제시하고, 근거와 원음을 함께 보여준다.

품질 차원 대응표 [41].

품질 차원	우리 점검	해당 절
정확성 (accuracy)	근거 대비 정밀도 감사	E2
완전성 (completeness)	역량 질문 통과 여부, 주입 오류 재현율	E1, E3
일관성 (consistency)	온톨로지 스키마·어휘 단서 검증 (구현은 SHACL 대신 코드 검사)	온톨로지 절
적시성 (timeliness)	유효 구간·무효화, 시점 스냅샷 질의	Fusion, CQ8
추적성 (provenance)	모든 사실에 원음 구간·전사 연결	전체

8 KG Exploration: Application

슬라이드 요점

- **제안 응용:** 지상 관제 상황 인식 보조와 사후 안전 분석 QA.
- **사용자:**
  - 관제 감독자: 최근 10 분간 복창 불일치 목록
  - 안전 분석가: 사건 전후 특정 항공편의 지시 이력과 원음 근거
  - 관제 교육생: 복창 패턴 피드백
- **예시 질문:** "*DAL2642* 가 *Lima 3* 에서 대기하라는 지시를 받고 제대로 복창했는가*?*" → 지시 사건, 복창 판정, 신뢰도, 원음 구간을 함께 답한다.

실제 KG 의 질의 결과 (DAL2642). 관제사는 콜사인을 번호만으로 불렀다 ("2642, ... taxi via Mike, hold for the Lima 3"). M5 가 직전 조종사 요청을 통해 이를 DAL2642 로 해소했다. 조종사 복창 ("Mike, hold short Lima 3, Delta 2642") 과 개념 단위로 비교한 결과는 MATCH 이고, 두 지시 모두 신뢰도 **HIGH**(교차 확인) 를 받았다. `hold for` 는 HOLD_SHORT 로 정규화되었다. 같은 구간을 다른 실행에서 전사하면 `on the ground` / `Lender Ground` 처럼 달라지는데, 이것이 **C2·C5**가 실제로 반복된다는 증거다.

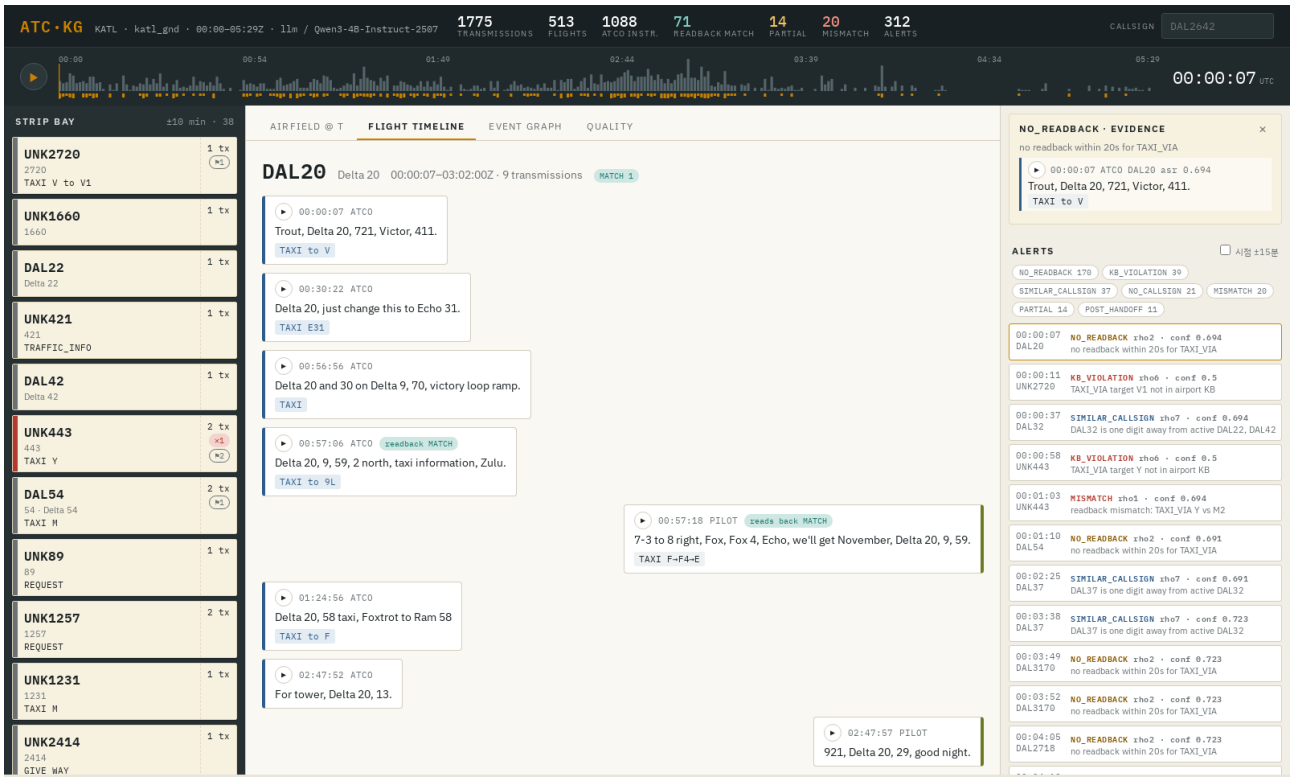


Figure 4: 웹 데모 (Flight timeline). 왼쪽은 시점 t 주변 항공편의 flight strip, 가운데는 관제사 (왼쪽)–조종사 (오른쪽) 2 열 교신 기록과 추출 개념, 오른쪽은 경보 목록과 근거 패널이다 (원음 구간 재생 가능). 위쪽은 분당 송신 수와 경보를 보여주는 시간 스크러버다.

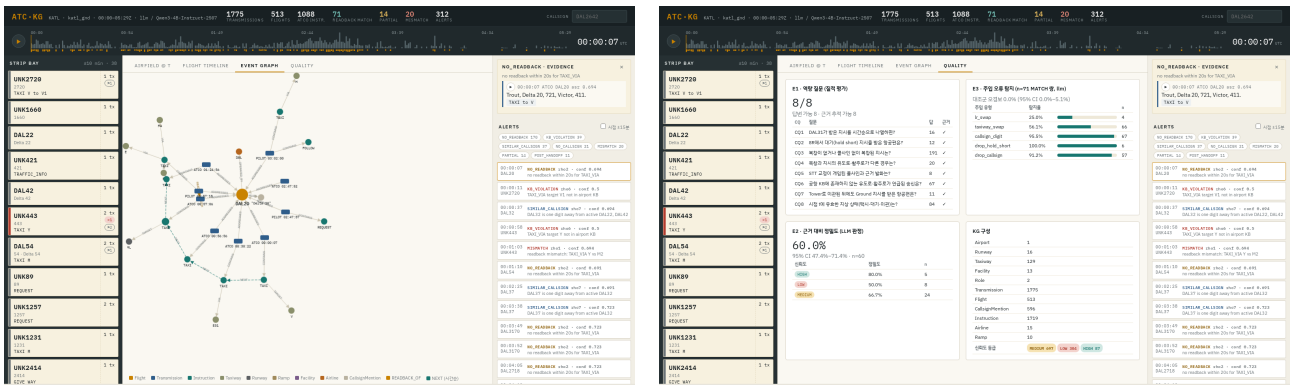


Figure 5: 왼쪽: 선택한 항공편의 사건 그래프 (송신·지시·유도로, READBACK_OF 와 NEXT 간선). 오른쪽: 품질 탭 (E1–E3 결과와 KG 구성).

Team 2 데모와의 차별점. Team 2 는 회사 네트워크 그래프와 근거 문장이 중심이다. 우리는 관제 현장의 *flight progress strip* 은유를 쓰고, **시간축** (스크러버, 시점 스냅샷) 과 **원음 근거 재생**을 중심에 둔다. Temporal KG 라는 우리 문제의 핵심을 화면 구조에서 바로 보여주기 위해서다.

9 Conclusions

Contributions (실측)

- 음성 교신을 입력으로 하는 사건 중심 *Temporal KG*. 기존 ATM KG(정형 데이터) 와 음성 복창 탐지 (발화 단위) 사이의 공백을 잇는다.
- 모든 사실에 원음 근거·신뢰도·유효 구간이 붙는다. 경보를 사람이 바로 검증할 수 있다.
- 무료 공개 데이터, 학습 없는 파이프라인, 지역 자원 교체로 확장 가능한 구조 (RQ4).
- 5.84 시간 실제 KATL 교신에서 항공편 513 개, 관제 지시 1,088 개, 복창 링크 105 개를 구축했다. 주입 오류 탐지에서 콜사인 이상 91–96%, 오경보 0%.

Takeaways

- 교차 확인 (HIGH) 의 정밀도가 가장 높았다 (80%, 잠정). Team 2 의 "두 출처 일치" 와 같은 경향이다.
- 관제사는 콜사인을 번호만으로 자주 부른다. 그래프 문맥 (활성 항공편) 으로 해소하는 단계가 필수다.
- 고정 온톨로지와 정규화 단계가 있어야 개념 단위 비교가 가능하다.

Limitations

- KATL Tower 부재로 착륙 허가 시나리오는 보조 데이터가 필요하다.
- 하루치 일부 (지상 5.84 시간) 와 STT 오류가 남는다. 실제 복창 오류는 드물어서 탐지 평가는 주입에 의존한다.
- 해소되지 않은 콜사인 (`UNK*`) 이 많고, 복창 링크는 관제 송신의 약 10% 에만 생긴다. 실제 MISMATCH 경보에 거짓 경보가 섞여 있다.
- E2 는 아직 LLM 판정 (잠정) 뿐이다. 사람 라벨이 필요하다.
- 추출과 일부 판정이 LLM 에 의존한다. 보안 자료는 로컬 LLM 으로 제한된다.

Next steps

- ADS-B(OpenSky) 결합으로 콜사인 해소와 위치 검증 강화.
- Tower·Approach 피드 추가, 다중 주파수 이관 연결.
- 한국 공역 확장 (한영 혼용 처리, AIP Korea 정적 KB).

A 논리 보강 내역

비어 있던 논리	보강 내용	근거
“왜 중요한가” 의 최신 정량 근거	FAA FY2023 활주로 침범 1,756 건, A/B 급 23 건, 원인 비율	[3]
“왜 이 공항인가”	KATL 세계 1 위 여객·운항, Ground 지시–복창 밀집 (실측)	[8], §3
콜사인 해소의 필요성	실측 콜사인의 88% 가 Delta, 3 초 간격 유사 콜사인 사례	[4], §3
평가 생략 시 데모의 대표성	역량 질문 질적 평가 + 소규모 근거 감사	[39, 40, 41]
외부 기준 데이터 없음 (재현율 측정 불가)	재현율을 이상 탐지 재현율로 재정의하고 통제된 오류 주입	[13, 6]
실제 오류가 드묾	주입 오류로 데모 시나리오 확보, 원음 기반 오경보율 병기	[6]
신뢰도 등급의 정당화	지시–복창을 독립 두 출처로 보는 교차 확인 정의 + E2 검증 가설	[1]
작은 표본의 통계	Wilson 95% 신뢰구간	[43]

References

[1] FAA. *Order JO 7110.65, Air Traffic Control*, §2-4-3 Pilot Acknowledgment/Readback.

[2] FAA. *Order JO 7340.2, Contractions*.

[3] FAA. Statement of Timothy L. Arel, COO Air Traffic Organization, U.S. Senate hearing (FY2023 runway incursion statistics). https://www.faa.gov/testimony/statement-timothy-l-arel-chief-operating-officer-air-traffic-organization-hearing-united

[4] Van Es, G. (NLR for EUROCONTROL). *Air-Ground Communication Safety Study: Causes and Recommendations*, 2005.

[5] Cardosi, K. M. *An Analysis of En Route Controller–Pilot Voice Communications*. DOT/FAA/RD-93/11, 1993.

[6] Cardosi, K. M. *An Analysis of Tower (Local) Controller–Pilot Voice Communications*. DOT/FAA/RD-94/15, 1994.

[7] Prinzo, O. V., Hendrix, A. M., Hendrix, R. *The Outcome of ATC Message Complexity on Pilot Readback Performance*. DOT/FAA/AM-06/25, 2006.

[8] Airports Council International. World airport traffic rankings 2024 (보도 기준: ATL 여객 약 1 억 800 만 명, 운항 1 위).

[9] Zuluaga-Gomez, J. et al. BERTraffic: BERT-based Joint Speaker Role and Speaker Change Detection for ATC Communications. *IEEE SLT*, 2023.

[10] Helmke, H. et al. Ontology for Transcription of ATC Speech Commands of SESAR 2020 Solution PJ.16-04. *DASC*, 2018.

[11] Kleinert, M. et al. Automated Interpretation of Air Traffic Control Communication: The Journey from Spoken Words to a Deeper Understanding of the Meaning. *DASC*, 2021.

[12] Helmke, H. et al. Readback Error Detection by Automatic Speech Recognition to Increase ATM Safety. *14th USA/Europe ATM R&D Seminar*, 2021.

[13] Helmke, H. et al. Readback error detection (HAAWAII, Isavia 실데이터 81% 탐지; 인공 복창 오류 표본을 사용한 관제사 실험). *SESAR Innovation Days*, 2022.

[14] Chen, S. et al. Effects of Language Ontology on Transatlantic Automatic Speech Understanding Research Collaboration in the ATM Domain. *Aerospace* 10(6):526, 2023.

[15] Keller, R. M. *The NASA Air Traffic Management Ontology*. NASA/TM-2017-219526, 2017.

[16] Keller, R. M. Building a Knowledge Graph for the Air Traffic Management Community. *Companion Proc. WWW*, 2019.

[17] Schrefl, M. et al. Creating an ATC Knowledge Graph in Support of the Artificial Situational Awareness System. *Transportation Research Procedia* 64:328–336, 2022.

[18] Mekerishvili, A. M., Sun, J., Jonk, P., de Vries, V. Structured Command Extraction from ATC Communications Using Open and Fine-Tuned Language Models. *SESAR Innovation Days*, 2025.

[19] Deng, Q. et al. SCOPE: A Lightweight-training LLM Framework for Air Traffic Control Readback Monitoring. arXiv:2605.29543, 2026.

[20] Zhang, B., Soh, H. Extract, Define, Canonicalize: An LLM-based Framework for Knowledge Graph Construction. *EMNLP*, 2024.

[21] Feng, X., Wu, X., Meng, H. Ontology-grounded Automatic Knowledge Graph Construction by LLM under Wikidata Schema. *HI-AI@KDD*, 2024.

[22] LLM-empowered Knowledge Graph Construction: A Survey. arXiv:2510.20345, 2025.

[23] Lairgi, Y. et al. iText2KG: Incremental Knowledge Graphs Construction Using Large Language Models. *WISE*, 2024.

[24] Lairgi, Y. et al. ATOM: AdapTive and OptiMized Dynamic Temporal Knowledge Graph Construction Using LLMs. arXiv:2510.22590, 2025.

[25] Rasmussen, P. et al. Zep: A Temporal Knowledge Graph Architecture for Agent Memory. arXiv:2501.13956, 2025.

[26] Noy, N., Rector, A. (eds.) *Defining N-ary Relations on the Semantic Web*. W3C Note, 2006.

[27] Knez, T., Žitnik, S. Event-Centric Temporal Knowledge Graph Construction: A Survey. *Mathematics* 11(23):4852, 2023.

[28] Willard, B. T., Louf, R. Efficient Guided Generation for Large Language Models. arXiv:2307.09702, 2023.

[29] Knublauch, H., Kontokostas, D. (eds.) *Shapes Constraint Language (SHACL)*. W3C Recommendation, 2017.

[30] Nigmatulina, I. et al. A Two-Step Approach to Leverage Contextual Data: Speech Recognition in Air-Traffic Communications. *ICASSP*, 2022.

[31] Zuluaga-Gomez, J. et al. Contextual Semi-Supervised Learning: An Approach to Leverage Air-Surveillance and Untranscribed ATC Data in ASR Systems. *Interspeech*, 2021.

[32] nyuuzyou. *LiveATC Recordings (Partial 2024-08-26)*. Hugging Face Datasets. LiveATC.net Terms of Use 적용.

[33] Zuluaga-Gomez, J. et al. ATCO2 corpus. *DMLR*, 2024. arXiv:2211.04054

[34] Šmídl, L. et al. Air Traffic Control Communication (ATCC) Speech Corpora and Their Use for ASR and TTS Development. *Language Resources and Evaluation* 53, 2019.

[35] Hofbauer, K., Petrik, S., Hering, H. The ATCOSIM Corpus of Non-Prompted Clean Air Traffic Control Speech. *LREC*, 2008.

[36] Pellegrini, T. et al. The Airbus Air Traffic Control Speech Recognition 2018 Challenge. *Interspeech*, 2019.

[37] Godfrey, J. J. *Air Traffic Control Complete* (ATC0). LDC94S14A, 1994.

[38] Patrikar, J. et al. Image, Speech, and ADS-B Trajectory Datasets for Terminal Airspace Operations. *Scientific Data*, 2025.

[39] Grüninger, M., Fox, M. S. Methodology for the Design and Evaluation of Ontologies. *IJCAI-95 Workshop on Basic Ontological Issues in Knowledge Sharing*, 1995.

[40] Noy, N. F., McGuinness, D. L. *Ontology Development 101: A Guide to Creating Your First Ontology*. Stanford KSL-01-05, 2001.

[41] Zaveri, A., Rula, A., Maurino, A., Pietrobon, R., Lehmann, J., Auer, S. Quality Assessment for Linked Data: A Survey. *Semantic Web* 7(1):63–93, 2016.

[42] Zheng, L. et al. Judging LLM-as-a-Judge with MT-Bench and Chatbot Arena. *NeurIPS Datasets and Benchmarks*, 2023.

[43] Wilson, E. B. Probable Inference, the Law of Succession, and Statistical Inference. *JASA* 22(158):209–212, 1927.